Propuesta de proyecto de grado

1. **Título del Proyecto.**

   Segmentación automática de columna vertebral y vértebras en radiografías con escoliosis para entornos con recursos computacionales limitados.

2. **Organización/Grupo de investigación.**

   El proyecto se desarrolla en la **Maestría en Inteligencia Artificial (MAIA)** de la **Universidad de los Andes** y se articula con el **Grupo de Ingeniería Biomédica de la Universidad de los Andes**, en el área de visión por computador aplicada a imágenes médicas. El equipo de trabajo está conformado por Jason Rosher Morrill, John Williams Morrill, David Alan Delgado Zarco y Octavio Esquivel Álvarez del Castillo.

   El trabajo contará con respaldo académico de **Luis Felipe Giraldo, Profesor Asociado**, y **Christian Javier Cifuentes, Profesor Asociado**, quienes aportan experiencia en analítica biomédica, aprendizaje automático y validación experimental en aplicaciones clínicas. Esta articulación entre MAIA e IBIO garantiza acceso a conocimiento de dominio, criterios de evaluación técnicamente pertinentes y acompañamiento metodológico para la investigación.

3. **Contexto, problema y justificación. Impacto esperado.**

   a) Situación actual y contexto. La escoliosis es una deformidad tridimensional de la columna vertebral cuyo seguimiento clínico se realiza principalmente mediante radiografías anteroposteriores. En la práctica médica, la severidad se cuantifica con el ángulo de Cobb, para cuyo cálculo es necesario identificar vértebras límite y trazar líneas sobre placas terminales. Este flujo es dependiente del observador, consume tiempo clínico y puede introducir variabilidad entre especialistas.

   b) Problema a abordar. La segmentación automática en radiografías 2D es especialmente desafiante por la superposición de estructuras, la variabilidad morfológica entre pacientes, las diferencias de escala y campo de visión, la posible presencia de columna incompleta y el ruido en las anotaciones. Aunque existen modelos potentes basados en CNN y Transformers, muchos de ellos priorizan patrones locales o relaciones contextuales globales sin incorporar de manera explícita restricciones topológicas y geométricas propias de la anatomía vertebral. Esta brecha es especialmente relevante cuando se busca consistencia anatómica vértebra a vértebra y robustez frente a imágenes de calidad heterogénea.

   Formalmente, dada una radiografía $I : \Omega \to \mathbb{R}$, con $\Omega \subset \mathbb{R}^2$, se busca estimar:

   $$f_\theta : I \to Y,$$

   donde $Y : \Omega \to \{0, 1, \ldots, C-1\}$ representa una máscara multiclase por vértebra. El problema de

aprendizaje se plantea como:

$$\theta^* = \arg\min_{\theta} \; \mathbb{E}_{(I,Y)\sim\mathcal{D}} \left[\mathcal{L}(f_\theta(I), Y)\right].$$

c) Justificación e impacto esperado. Se propone un modelo híbrido **CNN + TDA + Transformer multi-kernel** para mejorar la coherencia anatómica de la segmentación y facilitar la estimación automática del ángulo de Cobb. El impacto esperado incluye: i) reducción de la variabilidad en la medición radiológica; ii) aumento de la reproducibilidad en el seguimiento clínico; iii) disminución del tiempo de análisis manual; y iv) habilitación futura de herramientas portables o desplegables en entornos con restricciones de cómputo, manteniendo al sistema como soporte a la decisión clínica y no como sustituto del especialista.

4. **Objetivos.**

Objetivo general. Desarrollar y evaluar un modelo híbrido basado en CNN, análisis topológico de datos y Transformers kernelizados para la segmentación automática de vértebras y la estimación del ángulo de Cobb en radiografías de columna vertebral.

Objetivos específicos.

- Diseñar e implementar tres configuraciones comparables bajo un mismo protocolo experimental: **Baseline CNN**, **CNN + Transformer** y **CNN + TDA + Transformer multi-kernel**.
- Cuantificar el desempeño de segmentación mediante métricas de solapamiento como **IoU o Dice Score**, tanto para la columna vertebral como para la segmentación de cada vértebra.
- Evaluar la utilidad clínica del sistema mediante el error en la estimación del ángulo de Cobb respecto a la referencia disponible.
- Medir la eficiencia computacional del modelo en términos de tiempo y memoria de inferencia, con énfasis en su viabilidad futura para escenarios de recursos limitados.
- Determinar el aporte incremental de los descriptores topológicos, del componente geométrico y de la atención multi-kernel mediante estudios de ablación y comparación con la línea base.

5. **Estado del arte.**

En segmentación médica, arquitecturas como *U-Net* y variantes auto-configurables como *nnU-Net* constituyen líneas base sólidas para tareas densas de segmentación. En el dominio de columna y vértebras, trabajos recientes han incorporado Transformers para capturar dependencias anatómicas de largo alcance y mejorar la consistencia estructural, especialmente en CT y en escenarios con campo de visión arbitrario.

Se identifican tres líneas principales de literatura relevante: *(i)* arquitecturas encoder-decoder enriquecidas con atención global (por ejemplo, ViT/Swin integrados a U-Net), *(ii)* enfoques tipo DETR o *vertebra-aware transformers* para etiquetado/segmentación de vértebras, y *(iii)* métodos de preservación topológica mediante pérdidas o restricciones inspiradas en homología persistente. Esta última línea es especialmente importante, porque aporta una base teórica para preservar conectividad, continuidad y coherencia estructural en segmentación.

La brecha identificada es que la topología y la geometría explícita suelen estar subrepresentadas en la mayoría de soluciones para imágenes médicas de columna. Se utilizan centroides, bordes o codificación posicional, pero rara vez se integran de forma conjunta descriptores de homología persistente, relaciones geodésicas o atención multi-kernel informada por estructura anatómica. Esta limitación es más notoria en radiografías 2D, donde la proyección, la oclusión y la calidad de adquisición dificultan la separación consistente entre vértebras. El proyecto propone cerrar esta brecha combinando representaciones convolucionales locales, descriptores topológicos y atención kernelizada sobre espacios estructurados.

6. **Metodología y solución propuesta.**

   Se propone un pipeline con cinco etapas complementarias:

   - **Extracción local (CNN):** obtención de *feature maps* y embeddings anatómicos a partir de la radiografía.
   - **Enriquecimiento topológico (TDA):** construcción de complejos simpliciales (por ejemplo, Vietoris-Rips) y extracción/vectorización de descriptores topológicos relevantes.
   - **Componente geométrico (manifold):** incorporación de estructura geométrica intrínseca sobre el espacio de embeddings para modelar continuidad anatómica.
   - **Transformer multi-kernel:** cada cabeza de atención opera con kernels distintos (lineal, RBF, coseno o polinomial) según el espacio de representación y el tipo de relación que se desea enfatizar.
   - **Decodificación densa:** generación de máscara multiclase vértebra a vértebra y cálculo de métricas derivadas, incluyendo ángulo de Cobb.

   Diagrama funcional de la solución propuesta:

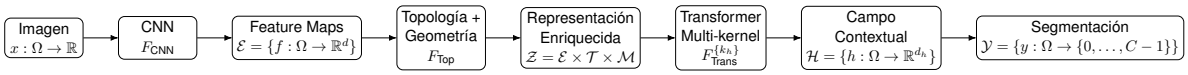

   Flujo funcional resumido del modelo:

$$F = F_{\text{Dec}} \circ F_{\text{Trans}}^{\{k_h\}} \circ F_{\text{Top}} \circ F_{\text{CNN}}.$$

   Para una imagen de entrada $I \in \mathbb{R}^{H \times W}$, el flujo de representación se describe como:

$$I \xrightarrow{\phi} Z^{cnn} \xrightarrow{\tau} Z^{topo} \xrightarrow{k} \tilde{Z} \xrightarrow{\mathcal{T}} \hat{Y}.$$

   En la atención kernelizada por cabeza h, se define:

$$(K_h)_{ij} = k_h(t_i, t_j), \qquad A_h(i,j) = \frac{\exp((K_h)_{ij})}{\sum_{j'=1}^{n} \exp((K_h)_{ij'})},$$

   y

$$\text{head}_h(i) = \sum_{j=1}^{n} A_h(i,j) V_h(t_j).$$

Como kernels candidatos se consideran, entre otros:

$$k_{linear}(x_i, x_j) = x_i^\top x_j, \qquad k_{RBF}(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right),$$

$$k_{poly}(x_i, x_j) = (x_i^\top x_j + c)^p.$$

Herramientas y plataforma experimental. La implementación se realizará en Python, empleando librerías de aprendizaje profundo y seguimiento experimental. Para trazabilidad y comparación de corridas se utilizará *MLflow*; para orquestación de procesos asíncronos y paralelos se contempla *asyncio*, *ProcessPoolExecutor* o *Ray*; y para desacoplamiento por eventos se consideran esquemas tipo *Pub/Sub* o *SNS/SQS*. La experimentación se ejecutará sobre infraestructura con soporte GPU.

Fases metodológicas. El proyecto se organizará en cinco fases: i) preparación y perfilamiento de datos; ii) implementación del baseline CNN; iii) incorporación de TDA y componente geométrico; iv) integración del Transformer multi-kernel; y v) evaluación comparativa, ablaciones y análisis final.

7. **Exploración y descripción de los datos.**

El dataset contiene radiografías anteroposteriores de columna de pacientes con y sin escoliosis, con diferentes niveles de anotación:

- Radiografía original en escala de grises.
- Máscara binaria de columna.
- Segmentación multiclase por vértebra (etiquetas independientes).
- Curva espinal estimada a partir de la segmentación.
- Métricas clínicas asociadas (incluyendo ángulo de Cobb).

Fuente y tamaño del dataset. El conjunto de datos utilizado en este proyecto se enmarca en el Grupo de Ingeniería Biomédica de la Universidad de los Andes y corresponde a un conjunto de más de 200 radiografías anteroposteriores de columna completa, con anotaciones de máscara de la columna vertebral y de cada vértebra. El dataset incluye casos con y sin escoliosis, cubriendo distintos grados de curvatura y variabilidad anatómica. Todas las imágenes se encuentran anonimizadas, no contienen datos personales identificables y su uso está restringido al desarrollo académico e investigativo. Dado que las anotaciones son propias, su utilización requiere acuerdo de confidencialidad. Para fines experimentales, los datos se dividirán en entrenamiento, validación y prueba, asegurando separación por paciente para evitar fuga de información entre subconjuntos.

Criterios de inclusión y exclusión. Se incluirán estudios radiográficos anteroposteriores con calidad diagnóstica suficiente, presencia visible de la columna torácica y lumbar en el campo de visión, y disponibilidad de anotaciones utilizables para segmentación y/o medición clínica. Se excluirán estudios con artefactos severos, imágenes incompletas, etiquetas inconsistentes o casos en los que no sea posible identificar de manera confiable las vértebras de interés.

Anotación y control de calidad. Las máscaras y referencias clínicas corresponden a anotaciones propias asociadas al conjunto de datos utilizado en el proyecto. Como parte del control de calidad, se realizará una revisión de consistencia de etiquetas, detección de vértebras incompletas, corrección de clases ambiguas y validación visual de overlays para asegurar coherencia anatómica entre

imagen y segmentación. Adicionalmente, se verificará la integridad de los estudios y la separación por paciente antes de la partición experimental, con el fin de reducir riesgo de fuga de información y sesgos de validación.

Limitaciones y sesgos potenciales: variabilidad en resolución/contraste, superposición de estructuras anatómicas en 2D, diferencias de morfología vertebral entre pacientes y posibles inconsistencias en anotaciones.

Estrategia de preparación: estandarización de formato, control de calidad de etiquetas, partición entrenamiento-validación-prueba y definición de flujos de preprocesamiento orientados a mejorar robustez ante variaciones de escala y ruido.

Además de las máscaras, el dataset incluye representaciones derivadas (curva espinal y overlays con métricas clínicas), lo cual permite evaluar consistencia anatómica global y no solo desempeño por píxel.

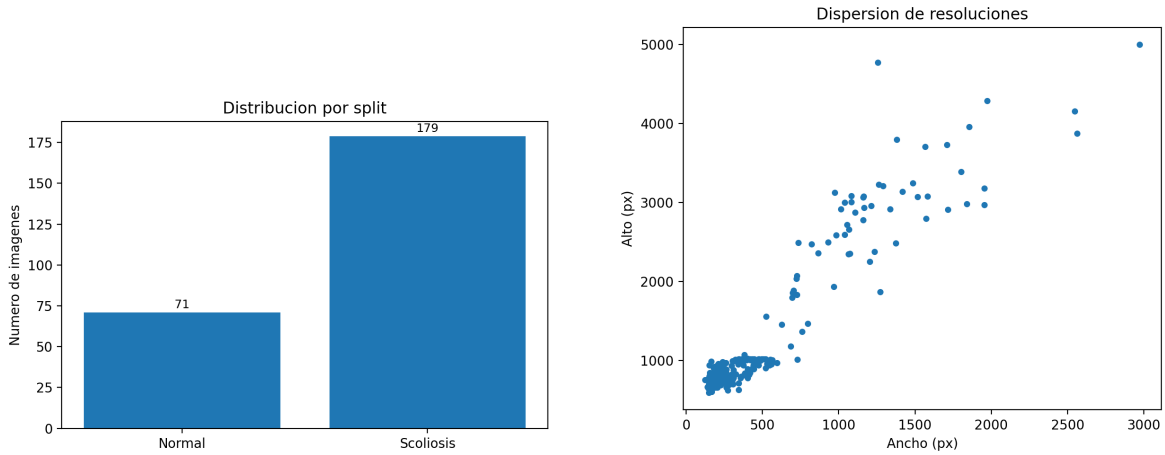

Figura. Diagnóstico exploratorio del dataset: distribución de muestras por clase y dispersión de resoluciones de las radiografías.

Desafíos identificados. Los principales retos son: i) heterogeneidad en resolución y contraste; ii) superposición de estructuras anatómicas en 2D; iii) diferencias morfológicas entre pacientes y grados de deformidad; iv) presencia de múltiples estudios por paciente; y v) disponibilidad no homogénea de métricas clínicas derivadas, ya que estas aparecen principalmente en los casos con escoliosis. Estos factores justifican un protocolo cuidadoso de partición, validación y análisis de sesgos.

8. **Consideraciones éticas.**

El proyecto contempla los principios de privacidad, equidad, transparencia y uso responsable en contexto médico:

- **Privacidad y seguridad.** Las radiografías están anonimizadas y su uso se limita al entorno académico/investigativo. La gestión de artefactos y experimentos se realizará sobre infraestructura controlada, con acceso restringido a los datos y trazabilidad de las ejecuciones.
- **Sesgos y representatividad.** Existe desbalance entre estudios normales y estudios con esco-

liosis, así como variabilidad potencial en calidad de imagen y severidad de la deformidad. Para mitigar este riesgo se evaluarán pérdidas ponderadas, monitoreo por subgrupos y análisis desagregado del desempeño.

- **Transparencia.** El sistema se concibe como soporte a la decisión clínica. Se priorizará la visualización de la segmentación, de la línea central estimada y de los elementos anatómicos utilizados en el cálculo del ángulo de Cobb para facilitar auditoría técnica por parte del especialista.
- **Impacto social.** La propuesta no busca sustituir al profesional de salud, sino reducir carga operativa, apoyar el seguimiento y ampliar acceso a herramientas de análisis en contextos con menor disponibilidad de especialistas.

9. **Evaluación y métricas.**

La evaluación se realizará comparando tres configuraciones: **Baseline CNN**, **CNN + Transformer**, y **CNN + TDA + Transformer multi-kernel**.

Criterios y métricas principales:

- Calidad de segmentación por vértebra (p. ej., Dice y métricas complementarias de precisión/F1 según la configuración experimental).
- Coherencia anatómica global de la segmentación, apoyada en la revisión de continuidad estructural de la columna y en las representaciones derivadas disponibles, como curva espinal y overlays con métricas clínicas.
- Error en la estimación del ángulo de Cobb respecto a la referencia disponible.
- Eficiencia computacional y estabilidad de entrenamiento.

Se incluirán estudios de ablación para cuantificar el aporte de descriptores topológicos, kernels de atención y componente geométrico. El diseño experimental contempla tres escenarios: **Baseline CNN**, **CNN + Transformer** y **CNN + TDA + Transformer multi-kernel**, con validación comparativa bajo el mismo protocolo de partición de datos.

Como referencia del mecanismo base de atención contextual, también se considerará la formulación estándar:

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V.$$

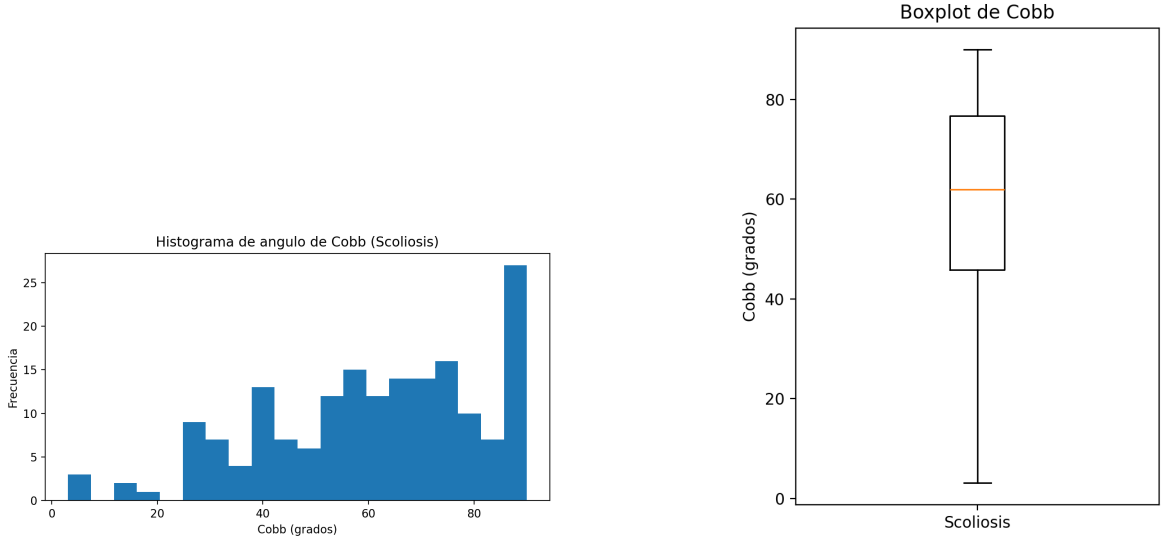

Figura. Distribución del ángulo de Cobb en el subconjunto de escoliosis (histograma y boxplot), útil para interpretar sesgo de severidad y estrategia de validación.

10. **Cronograma.**

En coherencia con el formato del proyecto de grado, se propone un plan de trabajo de **8 semanas** para el segundo ciclo:

- **Semana 1:** perfilamiento del dataset, validación de integridad y definición del protocolo de partición por paciente.
- **Semana 2:** preprocesamiento y construcción del baseline CNN.
- **Semana 3:** ajuste del baseline y definición del protocolo final de evaluación.
- **Semana 4:** incorporación de descriptores topológicos y validación intermedia.
- **Semana 5:** integración del componente geométrico y del Transformer multi-kernel.
- **Semana 6:** experimentos comparativos entre las tres configuraciones.
- **Semana 7:** estudios de ablación, análisis de eficiencia computacional y revisión de sesgos.
- **Semana 8:** consolidación de resultados, conclusiones y redacción final del informe.

Viabilidad y recursos. El plan es viable porque el dataset ya se encuentra identificado y estructurado, existen expertos de dominio que respaldan la evaluación y la infraestructura requerida se limita a recursos de cómputo con GPU, gestión de experimentos y orquestación paralela. El diseño considera como deseable la futura portabilidad a escenarios de recursos limitados, por lo que se medirán explícitamente memoria y tiempo de inferencia desde la etapa experimental.

11. **Bibliografía.**

Referencias preliminares:

- Ronneberger, O., Fischer, P., & Brox, T. (2015). *U-Net: Convolutional Networks for Biomedical Image Segmentation*. MICCAI.
- Isensee, F., Jaeger, P. F., Kohl, S. A. A., Petersen, J., & Maier-Hein, K. H. (2021). *nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation*. Nature Methods.
- Vaswani, A., et al. (2017). *Attention Is All You Need*. NeurIPS.
- Tao, R., Liu, W., & Zheng, G. (2022). *Spine-transformers: Vertebra labeling and segmentation in arbitrary field-of-view spine CTs via 3D transformers*. Medical Image Analysis.
- Zhang, Y., et al. (2023). *A Spine Segmentation Method under an Arbitrary Field of View Based on 3D Swin Transformer*. International Journal of Intelligent Systems.
- Li, X., et al. (2024). *VerFormer: Vertebrae-Aware Transformer for Automatic Spine Segmentation from CT Images*. Diagnostics.
- Aydogdu, S., et al. (2024). *Improving Vertebrae Segmentation Using a Centroid Detection-Guided Transformer-Based Network*. IEEE ISBI.
- Clough, J. R., et al. (2020). *A Topological Loss Function for Deep-Learning Based Image Segmentation Using Persistent Homology*. IEEE TPAMI.
- Hu, X., et al. (2019). *Topology-Preserving Deep Image Segmentation*. NeurIPS.
- Bronstein, M. M., Bruna, J., LeCun, Y., Szlam, A., & Vandergheynst, P. (2017). *Geometric Deep Learning: Going beyond Euclidean data*. IEEE Signal Processing Magazine.
- Edelsbrunner, H., & Harer, J. (2010). *Computational Topology: An Introduction*. American Mathematical Society.