Segmentación automática de columna vertebral y vértebras en radiografías con escoliosis para entornos con recursos computacionales limitados

Jason Rosher Morrill, John Williams Morrill, David Alan Delgado Zarco, Octavio Esquivel Álvarez del Castillo
Maestría en Inteligencia Artificial (MAIA)
Universidad de los Andes, Bogotá, Colombia
j.morrill@uniandes.edu.co, j.williams@uniandes.edu.co, d.delgado@uniandes.edu.co, o.esquivel@uniandes.edu.co

***Abstract*—La segmentación automática de la columna vertebral en radiografías es una tarea compleja debido a la superposición de estructuras anatómicas, variabilidad morfológica y limitaciones en la calidad de las imágenes. Los métodos actuales basados en redes convolucionales y Transformers han mostrado buenos resultados en tomografía computarizada, pero su aplicación en radiografías 2D sigue siendo limitada y depende frecuentemente de postprocesamientos heurísticos.**

En este trabajo se propone un modelo híbrido que combina redes convolucionales, análisis topológico de datos (TDA) y Transformers con atención kernelizada para mejorar la segmentación vertebral. El modelo incorpora descriptores topológicos y geométricos en el espacio de representación, permitiendo capturar simultáneamente información local, global y estructural.

La arquitectura propuesta introduce un Transformer multi-kernel donde cada cabeza de atención opera sobre distintos espacios de representación (CNN, topológico y manifold). Este enfoque busca mejorar la coherencia anatómica de la segmentación en radiografías con escoliosis.

El trabajo presenta el marco teórico y la metodología propuesta para integrar geometría diferencial y análisis topológico dentro de arquitecturas profundas para segmentación médica.

***Index Terms*—spine, vertebra segmentation, transformer, topological data analysis, persistent homology, differential geometry**

I. Introducción

La escoliosis es una deformidad tridimensional de la columna vertebral caracterizada por una curvatura lateral anormal acompañada de rotación vertebral. Esta condición puede progresar durante el crecimiento y afectar significativamente la postura, la función respiratoria y la calidad de vida de los pacientes. El diagnóstico y seguimiento clínico se realizan principalmente mediante radiografías anteroposteriores de columna vertebral.

La severidad de la escoliosis se evalúa clínicamente mediante el ángulo de Cobb, el cual se calcula identificando manualmente las vértebras límite de la curvatura y midiendo el ángulo formado entre sus placas terminales. Aunque este método es ampliamente utilizado en la práctica clínica, su estimación depende de la selección manual de puntos anatómicos, lo que introduce variabilidad entre observadores y reduce la reproducibilidad de las mediciones.

Los avances recientes en aprendizaje profundo han permitido desarrollar métodos automáticos para el análisis de imágenes médicas, incluyendo la segmentación de estructuras anatómicas y la estimación de métricas clínicas. Sin embargo, muchos enfoques se basan únicamente en representaciones locales aprendidas por redes convolucionales, sin incorporar explícitamente información geométrica o topológica de la estructura de la columna vertebral.

En este trabajo se propone un enfoque híbrido que combina redes convolucionales, análisis topológico de datos y modelos tipo Transformer para modelar la geometría de la columna vertebral a partir de radiografías. La idea central consiste en enriquecer las representaciones obtenidas por redes convolucionales con información estructural derivada de la segmentación vertebral, permitiendo estimar automáticamente métricas clínicas como el ángulo de Cobb y caracterizar la deformidad espinal.

Las principales contribuciones de este trabajo son:

- Un pipeline computacional para el análisis automático de radiografías de columna vertebral.
- La integración de representaciones geométricas y topológicas derivadas de la segmentación vertebral.
- Un marco experimental escalable para la ejecución paralela de experimentos y evaluación de modelos.
- La estimación automática de métricas clínicas relevantes para la evaluación de la escoliosis.

II. Objetivos

A. Objetivo general

Desarrollar un modelo híbrido basado en CNN, análisis topológico de datos y Transformers kernelizados para la segmentación automática de vértebras y la estimación del ángulo de Cobb en radiografías de columna vertebral.

B. Objetivos específicos

- Diseñar una arquitectura que combine representaciones convolucionales, topológicas y geométricas.
- Implementar un Transformer multi-kernel capaz de integrar múltiples espacios de representación.
- Evaluar el desempeño del modelo en tareas de segmentación vertebral utilizando métricas estándar de segmentación médica.
- Analizar el impacto de descriptores topológicos en la coherencia anatómica de la segmentación.

III. Estado del Arte

La segmentación automática de columna y vértebras ha evolucionado rápidamente con arquitecturas profundas que combinan extracción local de rasgos y modelado de contexto global. En tomografía computarizada (CT) 3D, predominan enfoques tipo U-Net y variantes modernas como nnU-Net, que han establecido baselines fuertes en segmentación médica y sirven como referencia para segmentación vertebral multi-etiqueta [**?**], [**?**]. Más recientemente, los Transformers se han incorporado para capturar dependencias de largo alcance y mejorar la consistencia anatómica, especialmente en escenarios de *arbitrary field-of-view* (FOV) donde el número de vértebras visibles y su escala varían [**?**], [**?**], [**?**], [**?**].

En el contexto Transformer, se observan dos tendencias principales. La primera adopta paradigmas tipo DETR para tratar la detección y el etiquetado vertebral como un problema de predicción de conjuntos mediante *query tokens* asociados a instancias anatómicas, que luego guían etapas de segmentación [**?**]. La segunda integra Transformers tipo ViT o Swin dentro de arquitecturas encoder–decoder tipo U-Net, operando sobre *patch tokens* o *feature tokens* para proveer contexto global en la segmentación densa [**?**], [**?**], [**?**]. En varios trabajos, la *anatomy-awareness* se introduce mediante tareas auxiliares y regularizadores geométricos simples, por ejemplo módulos de detección de bordes para reforzar la separación entre vértebras adyacentes, o aprendizaje multi-tarea con detección de centroides que aporta una señal global de localización y reduce errores en vértebras terminales o raras [**?**], [**?**], [**?**].

Sin embargo, pese a estos avances, la información geométrica y topológica incorporada en la mayoría de métodos revisados es limitada. En general, la "geometría" se reduce a cajas, centroides, mapas de borde o codificaciones posicionales estándar, sin incluir descriptores formales de geometría diferencial como curvatura o geodésicas, ni resúmenes topológicos provenientes de TDA, por ejemplo homología persistente o números de Betti [**?**], [**?**], [**?**], [**?**]. Esto es particularmente notorio en radiografías 2D (X-ray), donde los trabajos basados en Transformers son escasos y suelen depender de postprocesamientos heurísticos para corregir fusiones o incongruencias entre vértebras [**?**], [**?**]. En consecuencia, existe una oportunidad clara para modelos que representen explícitamente cada vértebra como un token anatómico enriquecido con descriptores topológicos y geométricos, y que utilicen atención informada por estructura para mejorar la fidelidad anatómica de la segmentación [**?**], [**?**].

IV. Marco Teórico

A. Redes Convolucionales para Segmentación Médica

B. Transformers en Visión Computacional

C. Análisis Topológico de Datos

D. Geometría Diferencial en Representaciones de Datos

V. Definición del Problema

Sea $I : \Omega \to \mathbb{R}$ una radiografía de columna vertebral, donde $\Omega \subset \mathbb{R}^2$ representa el dominio espacial de la imagen.

El objetivo del modelo es estimar una función de segmentación

$$f_\theta : I \to Y$$

donde

$$Y : \Omega \to \{0, 1, \ldots, C-1\}$$

representa una máscara de segmentación multiclase en la cual cada píxel es asignado a una de las C clases correspondientes a las vértebras de la columna vertebral o al fondo.

A partir de esta segmentación es posible derivar representaciones geométricas de la columna vertebral, incluyendo la línea central de la columna y métricas clínicas como el ángulo de Cobb.

El objetivo del aprendizaje consiste en encontrar los parámetros θ que minimizan una función de pérdida definida sobre el conjunto de entrenamiento

$$\theta^* = \arg\min_\theta \; \mathbb{E}_{(I,Y)\sim D}\left[\mathcal{L}(f_\theta(I), Y)\right]$$

donde D representa la distribución de datos del dataset.

VI. Metodología Propuesta

A. Visión General

Se propone un pipeline híbrido que combina redes convolucionales (CNN), análisis topológico de datos (TDA) y modelos tipo Transformer. La idea central consiste en enriquecer la representación de las imágenes médicas incorporando información tanto local como global, topológica y geométrica, con el objetivo de mejorar la segmentación de la columna vertebral y sus vértebras.

Formalmente, la imagen de entrada se modela como una función:

$$x : \Omega \to \mathbb{R}$$

donde $\Omega \subset \mathbb{R}^2$ es el dominio espacial de la radiografía.

El flujo general del modelo es el siguiente:

$$\texttt{Imagen} \to \texttt{CNN} \to \texttt{Feature Maps} \to \texttt{Enriquecimiento Topológico} \to \texttt{Transformer Multi-kernel} \to \texttt{Segmentación}$$

B. Diagrama del Pipeline

C. Interpretación

Cada bloque del pipeline puede interpretarse como una transformación entre espacios estructurados:

- $\mathcal{X}$: espacio de imágenes (funciones sobre Ω)
- $\mathcal{E}$: tensores (feature maps)
- $\mathcal{T}$: descriptores topológicos (homología persistente)
- $\mathcal{M}$: estructura geométrica (manifold)
- $\mathcal{Z}$: representación enriquecida
- $\mathcal{H}$: campos vectoriales contextualizados
- $\mathcal{Y}$: segmentación por píxel (vértebra a vértebra)

El modelo completo se expresa como:

$$F = F_{\text{Dec}} \circ F_{\text{Trans}}^{\{k_h\}} \circ F_{\text{Top}} \circ F_{\text{CNN}}$$

TABLE I: Resumen comparativo de enfoques recientes basados en Transformers para segmentación de columna/vértebras y el vacío que aborda la propuesta.

Familia / Idea	**Modalidad típica**	**Tokens en Transformer**	**Señal anatómica/geométrica usada**	**Limitación principal**	**Cómo se conecta con nuestra propuesta**
DETR/queries para vértebras (detección–etiquetado → segmentación)	CT 3D (arbitrary FOV)	*Query tokens* (instancia-like)	Relaciones globales vía atención + codificación posicional; geometría implícita (centros/cajas/esferas/pose)	Las queries no incorporan TDA/curvatura/geodésicas; la topología no entra al embedding ni a la atención	Reutilizamos la idea de *tokens anatómicos* pero los definimos por vértebra y los enriquecemos con TDA/geo
ViT/Swin + U-Net (segmentación densa single-stage)	CT 3D (multi-label), algunas variantes 2D	*Patch/feature tokens*	Contexto global; a veces manejo de FOV; priors anatómicos implícitos por supervisión	No hay tokens por vértebra; "estructura" aprendida es implícita; sin atención informada por cadena vertebral	Proponemos pasar de patches a *tokens por vértebra* y usar atención estructurada por anatomía
Refinamiento por bordes (edge modules + loss)	CT 3D	Patch/feature tokens (Transformer) + módulos CNN	Mapas de bordes / contornos para separar vértebras y afinar límites	Regularización local; no modela topología global ni relaciones vertebra–vertebra (geodésicas/curvatura)	Complementamos bordes con descriptores TDA/geo y atención sesgada por adyacencia
Multi-tarea con centroides (centroid-guided)	CT 2D (sagital/coronal), CT 3D; transferible a X-ray	Patch/feature tokens; centroides como señal auxiliar	Centroides/heatmaps guían segmentación; algunas pérdidas con restricciones anatómicas	No formaliza geodésicas/curvatura; no hay embeddings topológicos por vértebra	Usamos centroides/ROIs para construir tokens por vértebra y añadir descriptores TDA/geo
Transformers en X-ray 2D (segmentación genérica + postproceso)	X-ray 2D	Patch tokens	Postprocesamiento heurístico para separar regiones fusionadas	Muy poca anatomía explícita; topología corregida fuera del modelo	Objetivo: eliminar heurísticas integrando tokens vertebrales + TDA/geo dentro del modelo
Vacío (gap)	**X-ray 2D (nuestro foco)**	**Tokens por vértebra**	**TDA (persistencia/Betti) + geometría (curvatura/geodésicas) + sesgos de atención por adyacencia**	**No reportado como combinación integrada en la literatura reciente**	**Propuesta: vertebra-tokens enriquecidos → Transformer multi-kernel → decoder denso**

D. Asignación de Kernels por Espacio

El Transformer propuesto no utiliza únicamente el producto punto, sino que cada cabeza de atención opera con un kernel específico dependiendo del espacio de representación.

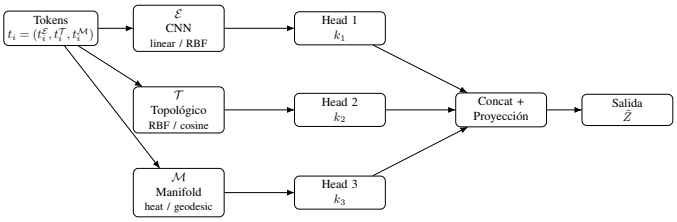

E. Interpretación del Transformer

El Transformer actúa como un operador que genera un campo contextual sobre la imagen:

$$F_{\text{Trans}}^{\{k_h\}} : \mathcal{Z} \to \mathcal{H}$$

donde cada cabeza implementa una noción distinta de similitud estructural mediante kernels. Esto permite capturar simultáneamente relaciones:

- locales (CNN),
- globales (atención),
- topológicas (TDA),
- geométricas (manifold).

F. Extracción de Características con CNN

Sea $x \in \mathcal{X}$ una imagen de entrada. Se utiliza una red convolucional para extraer características locales:

$$F_{\text{CNN}} : \mathcal{X} \to \mathcal{E}$$

donde $\mathcal{E} \subset \mathbb{R}^d$ es el espacio de embeddings.

G. Enriquecimiento Topológico

El embedding $z \in \mathcal{E}$ se transforma para incorporar información estructural global mediante herramientas topológicas.

1) Construcción de Complejo Simplicial:

$$F_{\text{simp}} : \mathcal{E} \to \mathcal{S}$$

2) Extracción de Características Topológicas (TDA):

$$F_{\text{TDA}} : \mathcal{S} \to \mathcal{T}$$

3) Suposición de Manifold:

$$F_{\text{man}} : \mathcal{E} \to \mathcal{M}$$

H. Representación Enriquecida

$$z_{\text{enriquecido}} = \text{concat}(z_{\text{CNN}}, z_{\text{TDA}}, z_{\text{manifold}})$$

I. Transformer Multi-kernel en Espacios Múltiples

A diferencia de un Transformer estándar (atención por producto punto), proponemos un bloque de atención donde cada cabeza opera con una noción de similitud dada por un *kernel*. La motivación es que distintos kernels pueden capturar mejor relaciones en diferentes espacios: euclídeo (CNN), topológico (TDA) y geométrico (manifold).

Sea $Z = \{t_i\}_{i=1}^n$ la secuencia de tokens derivada de $z_{\text{enriquecido}}$. Para cada cabeza $h \in \{1, \dots, H\}$ se define un kernel $k_h(\cdot,\cdot)$, y se construye una matriz de afinidad $K_h \in \mathbb{R}^{n\times n}$:

$$(K_h)_{ij} = k_h(t_i, t_j).$$

Los pesos de atención se obtienen normalizando por fila:

$$A_h(i,j) = \frac{\exp((K_h)_{ij})}{\sum_{j'=1}^n \exp((K_h)_{ij'})}.$$

La salida por cabeza se calcula como:

$$\text{head}_h(i) = \sum_{j=1}^n A_h(i,j)\, V_h(t_j),$$

y el bloque multi-cabeza se obtiene por concatenación y proyección:

$$\text{MHA}(t_i) = W_O\,[\text{head}_1(i) \,\|\, \cdots \,\|\, \text{head}_H(i)].$$

1) Asignación de kernels por espacio: Se define un conjunto finito de kernels candidatos $\mathcal{K}$ (p.ej., lineal, RBF, polinomial, coseno). Cada kernel se asocia a un espacio de representación:

- $\mathcal{E}$ (CNN): kernels sobre $z_{\text{CNN}} \in \mathbb{R}^d$.
- $\mathcal{T}$ (TDA): kernels sobre descriptores topológicos vectorizados z_{TDA}.
- $\mathcal{M}$ (manifold): kernels sobre coordenadas/embeddings que preservan geometría local.

2) Exploración y ablación: Se propone evaluar configuraciones donde:

- todas las cabezas usan el mismo kernel ($k_h \equiv k$),
- las cabezas se reparten entre kernels ($k_h \in \mathcal{K}$),
- comparación contra atención estándar (producto punto).

3) Aproximación Nyström (opcional): Para reducir el costo cuando n es grande, se plantea aproximar K_h con Nyström:

$$K_h \approx C_h\, W_h^{\dagger}\, C_h^{\top},$$

donde $r \ll n$ es el número de anclas. Esto preserva la estructura kernelizada con menor complejidad.

4) Diagrama del Bloque de Atención Multi-kernel:

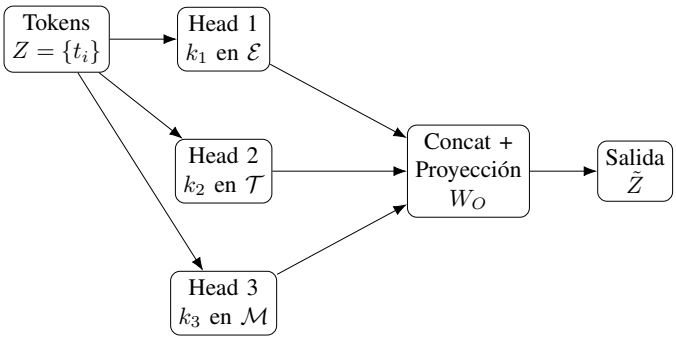

J. Procesamiento con Transformer

$$F_{\text{Trans}} : \mathcal{Z} \to \mathcal{Y}$$

K. Interpretación Categórica

El pipeline completo puede interpretarse como la composición de transformaciones entre espacios estructurados:

$$F = F_{\text{Trans}} \circ F_{\text{Top}} \circ F_{\text{CNN}}$$

L. Diagrama Funtorial

$$\mathcal{X} \xrightarrow{F_{\text{CNN}}} \mathcal{E} \xrightarrow{F_{\text{Top}}} \mathcal{Z} \xrightarrow{F_{\text{Trans}}} \mathcal{Y}$$

donde:

- $\mathcal{X}$: espacio de imágenes
- $\mathcal{E}$: espacio de embeddings
- $\mathcal{Z}$: representación enriquecida
- $\mathcal{Y}$: espacio de salida

M. Descomposición del Funtor Topológico

El enriquecimiento topológico se descompone como:

$$F_{\text{Top}} = F_{\text{TDA}} \circ F_{\text{simp}} \circ F_{\text{man}}$$

$$\mathcal{E} \xrightarrow{F_{\text{simp}}} \mathcal{S} \xrightarrow{F_{\text{TDA}}} \mathcal{T}$$

N. Tarea de Salida

Dependiendo del problema, la salida $\mathcal{Y}$ puede representar:

- Segmentación de la columna
- Clasificación de severidad
- Estimación del ángulo de Cobb

O. Dataset

El dataset utilizado contiene radiografías anteroposteriores de columna vertebral correspondientes a pacientes con y sin escoliosis. Cada imagen incluye diferentes niveles de anotación que permiten analizar la estructura anatómica de la columna.

Las representaciones disponibles incluyen:

- **Radiografía original**: imagen médica en escala de grises.
- **Máscara binaria**: segmentación de la columna vertebral donde los píxeles pertenecientes a la columna toman valor 255 y el resto corresponde al fondo.
- **Segmentación multiclase**: cada vértebra se representa con una etiqueta independiente (por ejemplo C7, T1–T12, L1–L5).
- **Curva espinal**: línea central de la columna estimada a partir de la máscara segmentada.
- **Métricas clínicas**: cálculo automático del ángulo de Cobb, utilizado para cuantificar la severidad de la escoliosis.

A partir de la segmentación es posible obtener representaciones geométricas de la columna vertebral. En particular, se puede estimar la línea central de la columna y calcular métricas clínicas como el ángulo de Cobb, ampliamente utilizado en la práctica médica para evaluar la severidad de la escoliosis.

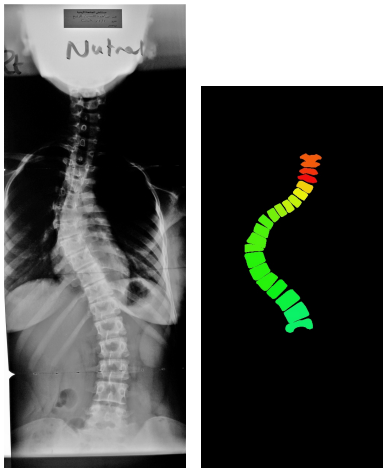

(a) Radiografía AP (b) Segmentación multiclase

Fig. 1: Ejemplos del dataset: (a) radiografía anteroposterior de columna y (b) segmentación multiclase de las vértebras.

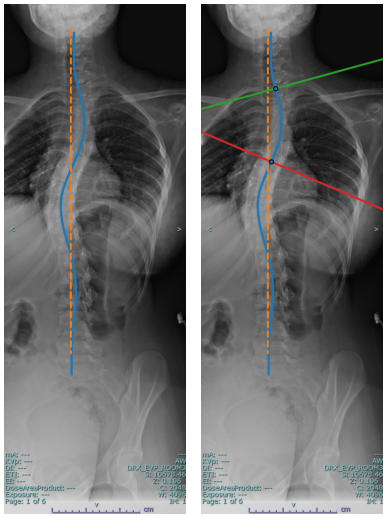

(a) Línea central estimada (b) Métricas clínicas (Cobb)

Fig. 2: Representaciones derivadas del dataset: (c) línea central estimada de la columna y (d) cálculo del ángulo de Cobb para evaluar la deformidad espinal.

P. Características del dataset

El dataset contiene radiografías anteroposteriores de columna vertebral anotadas a nivel de vértebra. Las imágenes presentan variabilidad en resolución, contraste y grado de deformidad espinal.

Entre los principales desafíos del dataset se encuentran:

- Superposición de estructuras anatómicas en radiografías 2D.
- Variabilidad en la morfología vertebral entre pacientes.
- Presencia de ruido e inconsistencias en las anotaciones.
- Diferencias en escala y campo de visión entre estudios.

Estas características hacen que la segmentación automática de vértebras sea un problema particularmente complejo en radiografías en comparación con modalidades 3D como CT o MRI.

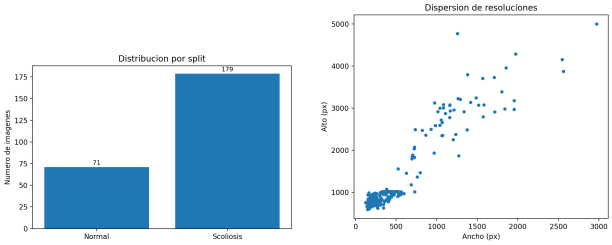

(a) Distribución de imágenes por split (b) Dispersión de resoluciones (ancho vs alto)

Fig. 3: Diagnóstico exploratorio del dataset. Se observa desbalance entre clases (Normal/Scoliosis) y alta variabilidad en resolución, lo cual justifica estrategias de preprocesamiento y partición cuidadosa por paciente.

Q. Preprocesamiento

R. Arquitectura del modelo

Una arquitectura de modelo que se utiliza combina la extracción profunda de características con la descripción geométrica del mundo real y el modelado contextual global. La intención es que el modelo capture los patrones locales (en el sitio de la radiografía) y la geometría global de la columna vertebral. Sea una radiografía de entrada

$$I \in \mathbb{R}^{H \times W},$$

donde H y W denotan las dimensiones de la imagen. El flujo completo del modelo puede verse como la composición

$$I \xrightarrow{\phi} Z^{cnn} \xrightarrow{\tau} Z^{topo} \xrightarrow{k} \tilde{Z} \xrightarrow{\mathcal{T}} \hat{Y}.$$

Todas estas transformaciones registran varios hechos estructurales de los datos.

1) Extracción de Características por CNN: La red neuronal convolucional para extraer características espaciales de la radiografía se realiza primero. Para el propósito de características formalizadas, la CNN define una función

$$f_\theta : \mathbb{R}^{H \times W} \to \mathbb{R}^{n \times d},$$

para transformar la imagen de entrada en un conjunto de incrustaciones

$$Z^{cnn} = f_\theta(I) = \{z_1, z_2, \ldots, z_n\}, \quad z_i \in \mathbb{R}^d.$$

Estos son descriptores locales de la anatomía de la columna vertebral (por ejemplo, bordes, texturas y patrones estructurales presentes en la imagen).

2) Estructura de Variedad y Geometría: Las incrustaciones producidas por la CNN representan puntos en un espacio euclidiano de dimensión d.

$$Z^{cnn} \subset \mathbb{R}^d.$$

Según la hipótesis de variedad, se asume que estos puntos están aproximadamente en una variedad de menor dimensión

$$\mathcal{M} \subset \mathbb{R}^d,$$

la geometría intrínseca de la estructura anatómica en la imagen. Esta interpretación permite explorar la estructura global de los datos mediante métodos geométricos y topológicos.

3) Complejos Simpliciales como Representación Topológica: Para representar las relaciones geométricas de los puntos de incrustación se forma un complejo simplicial utilizando la filtración de Vietoris–Rips.

$$Z = \{z_1, \ldots, z_n\}$$

sea el conjunto de incrustaciones. Para un parámetro de escala $\varepsilon > 0$, el complejo simplicial se define como

$$VR_\varepsilon(Z) = \{\sigma \subseteq Z : d(z_i, z_j) \leq \varepsilon \ \forall z_i, z_j \in \sigma\}.$$

Este complejo permite modelar la relación de conectividad entre los puntos y se utilizan propiedades topológicas para codificar el conjunto de incrustaciones. De esta estructura, se deriva un vector de características topológicas.

$$Z^{topo} = \tau(VR_\varepsilon(Z)) \in \mathbb{R}^{d_t},$$

donde τ representa un operador de resumen topológico.

4) Representación mediante Núcleo: Para modelar relaciones no lineales entre las incrustaciones desarrollamos una función de núcleo.

$$k(x_i, x_j) = \langle \Phi(x_i), \Phi(x_j) \rangle_{\mathcal{H}},$$

donde

- $\Phi(\cdot)$ es una función que proyecta los datos en un espacio de características de mayor dimensionalidad.
- $\mathcal{H}$ es un espacio de Hilbert con un producto interno.

Esta formulación define un espacio de representación no lineal conocido como el *Espacio de Hilbert de Núcleo Reproductor* (RKHS). Algunos núcleos comúnmente utilizados son

$$k_{linear}(x_i, x_j) = x_i^\top x_j$$

$$k_{RBF}(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right)$$

$$k_{poly}(x_i, x_j) = (x_i^\top x_j + c)^p.$$

El núcleo induce una matriz de similitud

$$K_{ij} = k(z_i, z_j),$$

que modela las relaciones estructurales entre las incrustaciones.

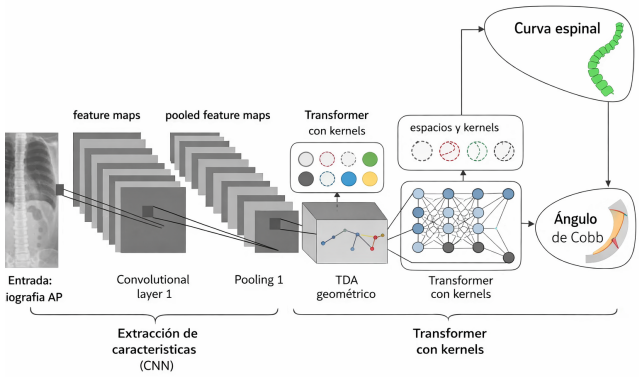

Fig. 4: Un esquema general del modelo propuesto. La entrada de la radiografía se procesa a través de una red convolucional para obtener mapas de características. Posteriormente, se integran representaciones topológicas y geométricas obtenidas utilizando las incrustaciones. Finalmente, un Transformer con núcleos estima la estructura de la columna vertebral y métricas clínicas, incluyendo el ángulo de Cobb, modelando las relaciones globales entre tokens.

5) Modelado Contextual Usando Transformer: Las incrustaciones enriquecidas se introducen en un codificador Transformer que captura relaciones entre diferentes tokens en un sentido global. Sea

$$\tilde{Z} = \{\tilde{z}_1, \ldots, \tilde{z}_n\}$$

el conjunto ordenado de tokens enriquecidos. Su mecanismo de autoatención se identifica como

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V.$$

El modelo completo puede expresarse en forma compacta como

$$\hat{Y} = \mathcal{T}\left(k\left(\tau\left(f_\theta(I)\right)\right)\right).$$

Esta formulación resume el flujo del modelo del sistema; la CNN produce características locales, los Complejos Simpliciales modelan la estructura geométrica de las incrustaciones, los núcleos enriquecen las representaciones basadas en relaciones, y luego un Transformer captura relaciones globales entre tokens.

S. Infraestructura Experimental

Con el fin de ejecutar múltiples configuraciones de entrenamiento de manera escalable, se propone una infraestructura experimental orientada a eventos y basada en procesamiento asíncrono. La arquitectura contempla un orquestador central que distribuye experimentos mediante una política *round robin*, un conjunto de *workers* que ejecutan los entrenamientos en paralelo, un controlador de *early stopping* y un sistema de mensajería para desacoplar la ejecución del registro de métricas y artefactos.

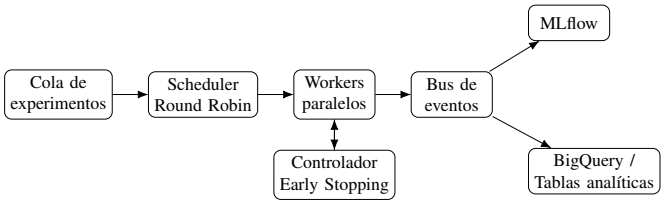

Fig. 5: Arquitectura general para la ejecución distribuida de experimentos.

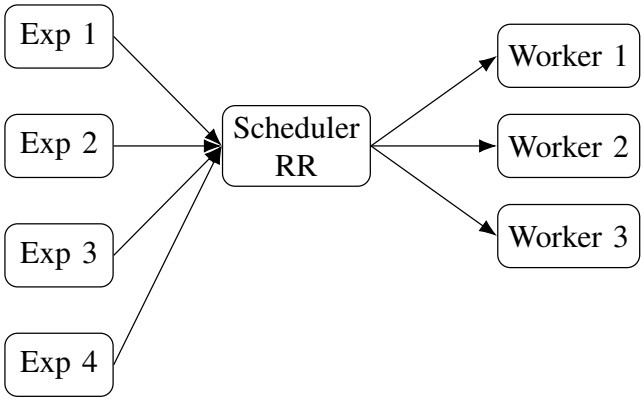

Fig. 6: Asignación de experimentos a *workers* mediante política round robin.

La motivación de esta arquitectura es separar claramente tres responsabilidades: (i) la planificación y asignación de experimentos, (ii) la ejecución paralela de los modelos y (iii) la persistencia y análisis de resultados. De esta forma, los procesos de entrenamiento no bloquean los componentes de monitoreo, y los resultados pueden almacenarse simultáneamente en sistemas de seguimiento de experimentos y en tablas analíticas en la nube.

1) Arquitectura General: El sistema parte de una cola de configuraciones de experimentos. Un *scheduler* central recibe estas configuraciones y las asigna de forma circular a los *workers* disponibles. Cada *worker* ejecuta un entrenamiento independiente y, al finalizar cada época, publica eventos con métricas parciales, estado de ejecución y artefactos generados. Dichos eventos son enviados a un sistema de mensajería (*Pub/Sub* en GCP o *SNS/SQS* en AWS), desde donde distintos consumidores actualizan MLflow y las tablas analíticas.

2) Política Round Robin y Paralelismo: La distribución de tareas se realiza mediante una política *round robin*, en la cual el planificador recorre cíclicamente la lista de *workers* activos y asigna el siguiente experimento al primer recurso disponible. Esta política permite balancear la carga de forma sencilla y mantener una ocupación uniforme del sistema.

En la implementación propuesta, la lógica de coordinación se mantiene asíncrona y no bloqueante, mientras que la ejecución de entrenamiento se delega a procesos paralelos, dado que el entrenamiento de modelos de aprendizaje profundo es intensivo en CPU/GPU y no se beneficia directamente de un modelo de concurrencia basado únicamente en corrutinas.

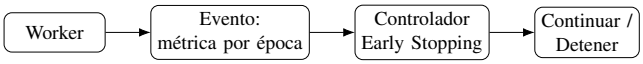

Fig. 7: Esquema de control para *early stopping* basado en eventos.

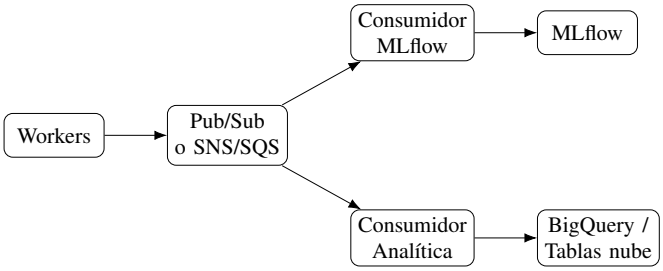

Fig. 8: Persistencia desacoplada de métricas, artefactos y tablas analíticas.

3) Early Stopping Basado en Eventos: Cada *worker* reporta métricas parciales al finalizar una época, tales como pérdida de validación, Dice, precisión o F1-score. Estas métricas son consumidas por un controlador de *early stopping*, el cual evalúa si un experimento debe continuar o detenerse anticipadamente. Este esquema evita desperdiciar recursos computacionales en configuraciones que ya no muestran mejora significativa.

El controlador no interfiere directamente con la lógica interna de entrenamiento, sino que opera como un servicio externo que observa eventos y emite decisiones de control. Esto permite mantener desacoplados el proceso de entrenamiento y la política de parada.

4) Persistencia de Métricas y Trazabilidad: Los eventos generados por los *workers* se envían a un bus de mensajería para permitir un esquema de *fan-out*. Desde este bus, un consumidor actualiza MLflow con parámetros, métricas y artefactos del experimento, mientras que otro consumidor escribe registros estructurados en tablas analíticas en la nube. Estas tablas pueden implementarse en BigQuery dentro de GCP o en servicios equivalentes en AWS.

Esta separación permite que el seguimiento de experimentos, la visualización de resultados y el análisis posterior se realicen sin bloquear la ejecución principal. Además, facilita la reproducibilidad y auditoría de los experimentos.

5) Implementación Propuesta: La implementación se desarrollará en Python, empleando librerías para concurrencia asíncrona, paralelismo de procesos, mensajería y seguimiento de experimentos. A nivel general, la API de control puede construirse con FastAPI; la orquestación asíncrona con `asyncio`; la ejecución paralela con `multiprocessing`, `ProcessPoolExecutor` o marcos distribuidos como Ray; el seguimiento de experimentos con MLflow; y la mensajería con clientes de Pub/Sub (GCP) o SNS/SQS (AWS).

Este diseño permite que el sistema sea modular, escalable y portable entre proveedores de nube, manteniendo desacopladas la ejecución de los entrenamientos, la política de parada anticipada y el almacenamiento analítico de los resultados.

El desarrollo del proyecto se divide en las siguientes fases:

1. Preparación del dataset y preprocesamiento de radiografías.
2. Implementación del modelo base basado en CNN.
3. Integración de representaciones topológicas (TDA).
4. Implementación del Transformer multi-kernel.
5. Ejecución de experimentos y análisis de resultados.

VII. Diseño Experimental

Los experimentos se diseñan con el objetivo de evaluar la contribución de cada componente del modelo propuesto.

En particular se consideran los siguientes escenarios experimentales:

- **Baseline CNN**: modelo basado únicamente en una red convolucional para segmentación.
- **CNN + Transformer**: incorporación de atención global mediante Transformer estándar.
- **CNN + TDA + Transformer**: modelo completo con representaciones topológicas y kernels múltiples.

Adicionalmente se realizarán estudios de ablación para analizar el impacto de:

- distintos kernels en las cabezas de atención,
- la inclusión de descriptores topológicos,
- la incorporación de la hipótesis de variedad en el espacio de embeddings.

A. Recursos computacionales

Los experimentos se ejecutarán utilizando infraestructura en la nube con soporte para GPU. La arquitectura propuesta permite distribuir el entrenamiento en múltiples workers para evaluar distintas configuraciones de hiperparámetros de manera paralela.

La implementación se desarrollará en Python utilizando bibliotecas de aprendizaje profundo y herramientas de seguimiento de experimentos como MLflow.

El cronograma contempla las siguientes fases:

- Implementación inicial del modelo base.
- Integración de representaciones topológicas.
- Ejecución de experimentos y análisis de resultados.
- Evaluación final y redacción del informe.

B. Entrenamiento

C. Métricas de Evaluación

VIII. Resultados

Los resultados del modelo se evaluarán utilizando el conjunto de prueba del dataset. Se analizará el desempeño en la segmentación de vértebras individuales y en la estimación de la curva espinal.

Se compararán distintas configuraciones del modelo, incluyendo variantes del Transformer con diferentes kernels y representaciones topológicas.

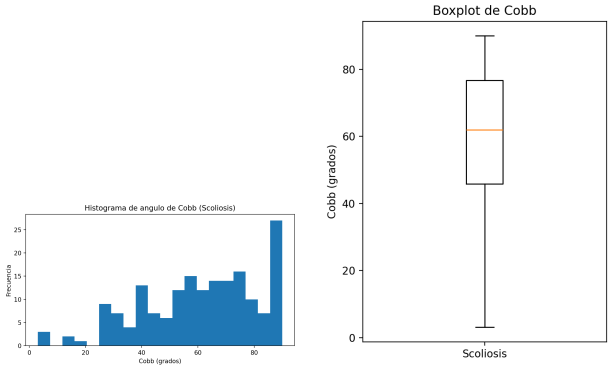

(a) Histograma del ángulo de Cobb (b) Boxplot del ángulo de Cobb

Fig. 9: Distribución de la severidad clínica en el subconjunto Scoliosis. La concentración de casos en rangos altos de Cobb sugiere un dataset sesgado hacia deformidades severas, aspecto que debe considerarse en la interpretación del desempeño del modelo.

IX. Análisis

El análisis se centrará en evaluar la contribución de cada componente del modelo. En particular se realizará un estudio de ablación para analizar el impacto de:

- La inclusión de descriptores topológicos.
- El uso de kernels distintos en las cabezas de atención del Transformer.
- La incorporación de estructura geométrica mediante la hipótesis de variedad.

X. Discusión

La integración de representaciones topológicas y geométricas dentro de arquitecturas profundas representa una dirección prometedora para mejorar la coherencia anatómica en segmentación médica. Se espera que el uso de descriptores estructurales permita capturar relaciones globales entre vértebras que no son fácilmente modeladas por redes convolucionales tradicionales.

XI. Conclusiones

XII. Trabajo Futuro

Como trabajo futuro se plantea extender el modelo a datasets clínicos más grandes, explorar representaciones topológicas más avanzadas y evaluar el modelo en escenarios clínicos reales.

También se investigará la incorporación de modelos generativos y aprendizaje auto-supervisado para mejorar la generalización en entornos con datos limitados.

References

[1] O. Ronneberger, P. Fischer, and T. Brox, "U-net: Convolutional networks for biomedical image segmentation," *MICCAI*, 2015.

[2] F. Isensee *et al.*, "nnu-net: a self-configuring method for deep learning-based biomedical image segmentation," *Nature Methods*, 2021.

[3] R. Tao, W. Liu, and G. Zheng, "Spine-transformers: Vertebra labeling and segmentation in arbitrary field-of-view spine cts via 3d transformers," *Medical Image Analysis*, vol. 75, p. 102258, 2022.

[4] Y. Zhang *et al.*, "A spine segmentation method under an arbitrary field of view based on 3d swin transformer," *International Journal of Intelligent Systems*, 2023.
[5] X. Li *et al.*, "Verformer: Vertebrae-aware transformer for automatic spine segmentation from ct images," *Diagnostics*, vol. 14, no. 17, p. 1859, 2024.
[6] S. Aydogdu *et al.*, "Improving vertebrae segmentation using a centroid detection-guided transformer-based network," in *IEEE ISBI*, 2024.
[7] J. R. Clough *et al.*, "A topological loss function for deep-learning based image segmentation using persistent homology," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2020.
[8] X. Hu *et al.*, "Topology-preserving deep image segmentation," in *NeurIPS*, 2019.
[9] M. Belkin and P. Niyogi, "Laplacian eigenmaps and spectral techniques for embedding and clustering," in *NeurIPS*, 2001.
[10] R. R. Coifman and S. Lafon, "Diffusion maps," *Applied and Computational Harmonic Analysis*, vol. 21, no. 1, pp. 5–30, 2006.